

Heston-Asian Opcióárazás: Elméleti bevezetés

Ábris

1. 0. Bevezetés, dolgozat célja.

Az ázsiai opciók kifizetése az eszköz árfolyamának egy meghatározott időszak alatti átlagától függ. A számtani átlagolású, rögzített kötési árfolyamú call opció esetében a kifizetési függvény a lejárat időpontban az árfolyam időbeli integrálján alapul. A kifizetési függvény, (ami a PDE megoldásának végfeltételeként szolgál), a következőképpen írható fel:

$$F(T, S, v, A) = \max \left(\frac{1}{T} \int_0^T S_\tau d\tau - K, 0 \right), \text{ ahol } A = \int_0^T S_\tau d\tau$$

Ebben a struktúrában a K jelöli a kötési árfolyamot, a T pedig a lejáratot.

Az egzotikus opciók árazása a modern pénzügyi matematika egyik legösszetettebb területe, különösen akkor, ha sztochasztikus volatilitással és útfüggő kifizetési struktúrákkal dolgozunk. A Heston modell alatt árazott Ázsiai opció beárazása egy négydimenziós parciális differenciálegyenlet megoldását követeli meg, ami a hagyományos numerikus eljárások számára jelentős kihívást jelent. Ebbe a környezetbe érkeznek meg a Physics-Informed Neural Networks (PINN) modellek, amelyek alapvetően változtatják meg a problémához való hozzáállásunkat azáltal, hogy a neurális hálózatok univerzális közelítő erejét ötvözik a pénzügyi matematika törvényszerűségeivel. A PINN lényege, hogy a modell tanítása során a veszteségfüggvénybe közvetlenül beágyazzuk magát a differenciálegyenlet rendszert, így a hálózat nem csupán adatokat interpolál, hanem megtanulja a mögöttes dinamikát is. A módszer egyik legnagyobb előnye a hagyományos rács-alapú eljárásokkal, például a véges differencia módszerrel szemben, az árfelület folytonossága. Míg az FDM csak véges számú ponton képes megadni a megoldást, addig a PINN hálómentes architektúrája lehetővé teszi, hogy tetszőleges pontokon kapjuk meg a megoldást, így magas dimenziószám mellett is skálázható marad. A

Monte Carlo szimulációkkal összevetve a PINN egy folytonos és sima becselőfüggvényt eredményez, lassú betanítást eredményez, viszont betanítás után konstans időbeli kiértékelésre képes, kiküszöbölve a szimulációkra jellemző statisztikai zajt és lassú konvergenciát. Különösen értékes tulajdonság az automatikus differenciálás lehetősége, amely révén az opciós görögök, mint a Delta vagy a Gamma, nagy pontossággal, és extra számítási költség nélkül nyerhetők ki a hálóból, elkerülve a zajos numerikus deriválást.

0. Világ megteremtése

Tegyük fel, hogy a pénzügyi piacokra teljesül az NFLVR. (No Free Lunch with Vanishing Risk) Ekkor Delbaen–Schachermayer tétel szerint létezik ekvivalens lokális maringálmérték Q , ami szükséges, és elégséges feltétele az arbitrázsmentességhez. Mivel két Wiener-folyamat hajtja a dinamikát, és csak egy kockázatos eszközünk van, ezért a piac nem teljes, azaz a pénzügyi matematika második alaptétele nem áll fenn rá, azaz nem egyértelmű az ekvivalens martingálmérték ($Q \sim P$)

1.1 A Kiinduló Sztochasztikus Differenciálegyenletek (SDE)

A levezetést a valós mérték (P) szerinti dinamikákból indítjuk. Az S_t a részvényárfolyam, v_t a variancia, A_t pedig az ázsiai opcióhoz szükséges Átlagár T-szerese.

Részvényárfolyam dinamikája

$$dS_t = \mu S_t dt + \sqrt{v_t} S_t dW_{1,t}$$

ahol μ a valós várható hozam.

Variancia dinamikája

$$dv_t = \kappa(\theta - v_t)dt + \sigma_v \sqrt{v_t} dW_{2,t}$$

Integrál dinamikája

Mivel $A_t = \int_0^t S_u du$, ennek differenciálja tisztán determinisztikus (nincs benne dW):

$$dA_t = S_t dt$$

Korrelációs szabály

A két Wiener-folyamat közötti kapcsolat:

$$dW_{1,t}dW_{2,t} = \rho dt$$

1.2 Mértékcseré

A kockázatsemleges árazás alapelve, hogy a diszkontált részvényárfolyamnak $(e^{-rt}S_t)$ lokális martingálnak kell lennie a Q mérték alatt, azaz a drift rS_t . Ebből meghatározható az árfolyamkockázat piaci ára, λ_1 :

$$\mu - \lambda_1 \sqrt{v_t} = r \quad \implies \quad \lambda_1 = \frac{\mu - r}{\sqrt{v_t}}$$

Itt egy fontos technikai feltételt kell rögzítenünk: mivel a λ_1 kockázati prémium kifejezésének nevezőjében a variancia gyöke szerepel, a mértékcserét definiáló sűrűségfolyamat martingál tulajdonsága sérülhet. Ha azonban fennáll a Feller-feltétel, azaz

$$2\kappa\theta \geq \sigma_v^2$$

akkor a volatilitás véges időn belül szigorúan pozitív marad. Ebben az esetben a mértékcseré folyamat várható értéke pontosan 1 lesz (Wong és Heyde, 2006, Theorem 3.5), azaz martingál lesz. Ennek fényében áttérhetünk a Q lokális martingálmértékre, ahol a kereskedhető eszköz dinamikája:

$$dS_t = rS_t dt + \sqrt{v_t} S_t d\widetilde{W}_{1,t}$$

Az árazáshoz elengedhetetlen a varianciafolyamat Q alatti dinamikájának meghatározása is. A szakirodalmat követve (Wong és Heyde, 2006) a mértékcseré után:

$$dv_t = \kappa^*(\theta^* - v_t)dt + \sigma_v \sqrt{v_t} d\widetilde{W}_{2,t}$$

lesz, ahol a kockázatsemleges mérték alatti paraméterek κ^* , θ^* a cikk szerint. Ezzel a (S_t, v_t) dinamikája jól definiált a Q mérték alatt.

1.3 A Bizonyítandó Parciális Differenciálegyenlet

A cél, hogy eljussunk az alábbi PDE-ig:

$$\begin{aligned} \frac{\partial U}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 U}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 U}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 U}{\partial v^2} \\ + rS\frac{\partial U}{\partial S} + \kappa^*(\theta^* - v_t)\frac{\partial U}{\partial v} + S\frac{\partial U}{\partial A} - rU = 0 \end{aligned}$$

Tudjuk, hogy a Girsanov tétel alkalmazása után az arbitrázsmentesség miatt: A Q mérték alatt az opció értékének teljes várható növekménye megegyezik az opcióba fektetett tőke futamidő alatti, kockázatmentes rátával vett elvárt hozamával:

$$E^Q[F(X_T) - F(X_t) \mid \mathcal{F}_t] = E^Q \left[\int_t^T rF(X_s) ds \mid \mathcal{F}_t \right]$$

Tétel: Itô-formula: Ha F kétszer folyamatosan deriválható n -változós függvény, és $(X_k)_{k=1}^n$ folytonos szemimartingálók, akkor tetszőleges t időpont-ra:

$$F(X(T)) - F(X(t)) = \sum_{k=1}^n \int_t^T \frac{\partial F}{\partial x_k}(X(s)) dX_k(s) + \frac{1}{2} \sum_{i,j} \int_t^T \frac{\partial^2 F}{\partial x_i \partial x_j}(X(s)) d[X_i, X_j](s).$$

Látható, hogy a Jobboldalon az első tag egy sztochasztikus integrál, a $dX_k(s)$ miatt, a második, pedig egy sima Stieltjes, a kvadratisz variáció miatt.

Ez azt jelenti az Itô-formula szerint, hogy egy lokális martingál szerinti kétszer folytonosan differenciálható függvény egy sztochasztikus integrál (vagyis lokális martingál), és egy korlátos függvény összegeként áll elő, vagyis egy szemimartingál.

Használjuk az Ito-formula definícióját.

$$\begin{aligned} F(X(T)) - F(X(t)) = \int_t^T \frac{\partial F}{\partial S} dS + \int_t^T \frac{\partial F}{\partial v} dv + \int_t^T \frac{\partial F}{\partial A} dA + \int_t^T \frac{\partial F}{\partial t} dt + \\ + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S^2} d[S, S] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial v^2} d[v, v] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A^2} d[A, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial t^2} d[s, s] + \end{aligned}$$

$$\begin{aligned}
& + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial A} d[S, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial t} d[S, s] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial S \partial v} d[S, v] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A \partial t} d[A, s] + \\
& + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial A \partial v} d[v, A] + \frac{1}{2} \int_t^T \frac{\partial^2 F}{\partial t \partial v} d[s, v]
\end{aligned}$$

Triviális, hogy azok a kvadratikus variációs tagok, amelyekben t van 0 -t adnak, így azok kiesnek, valamint $dA = Sds$ miatt ugyanez igaz az A -s tagokra is.

Most nézzük meg a maradék kvadratikus variációs tagokat, 3 tagot kell megvizsgálunk.:

$$\int_t^T \frac{\partial^2 F}{\partial S^2} d[S, S] = \int_t^T \frac{\partial^2 F}{\partial S^2} [\mu S_s ds + \sqrt{v_s} S_s dW_{1,s}] \stackrel{[W,s],[s,s]=0}{=} \int_t^T \frac{\partial^2 F}{\partial S^2} v_s S_s^2 ds$$

A fentebbi indokálás miatt ugyanúgy:

$$\int_t^T \frac{\partial^2 F}{\partial v^2} d[v, v] \stackrel{[W,s],[s,s]=0}{=} \int_t^T \frac{\partial^2 F}{\partial v^2} \sigma_v^2 v_s ds$$

Most nézzük meg $[v, S]$ -t:

$$\begin{aligned}
d[S, v] &= (\mu S_s ds + \sqrt{v_s} S_s dW_{1,s}) (\kappa(\theta - v_s) ds + \sigma_v \sqrt{v_s} dW_{2,s}) \stackrel{[W,s],[s,s]=0}{=} \sqrt{v_s} S_s dW_{1,s} \sigma_v \sqrt{v_s} dW_{2,s} \\
&= S_s \sigma_v v_s \rho ds
\end{aligned}$$

Azaz:

$$\int_t^T \frac{\partial^2 F}{\partial S \partial v} d[S, v] = \int_t^T \frac{\partial^2 F}{\partial S \partial v} S_s \sigma_v v_s \rho ds$$

. Behelyettesítve az SDE-ket:

$$\begin{aligned}
dF_s &= \frac{\partial F}{\partial S} (r S ds + \sqrt{v} S dW_1) + \frac{\partial F}{\partial v} (\kappa(\theta - v) ds + \sigma_v \sqrt{v} dW_2) + \frac{\partial F}{\partial A} (S ds) + \frac{\partial F}{\partial t} ds + \\
&+ \frac{1}{2} \frac{\partial^2 F}{\partial S^2} (v S^2 ds) + \frac{1}{2} \frac{\partial^2 F}{\partial v^2} (\sigma_v^2 v ds) + \frac{\partial^2 F}{\partial S \partial v} (\rho \sigma_v v S ds)
\end{aligned}$$

Átrendezve:

$$\begin{aligned}
dF_s &= \left[\frac{\partial F}{\partial t} + r S \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds + \\
&+ \left[\sqrt{v} S \frac{\partial F}{\partial S} dW_1 + \sigma_v \sqrt{v} \frac{\partial F}{\partial v} dW_2 \right]
\end{aligned}$$

Mostmár csak annyit kell belátnunk, hogy a második zárójelben lévő összeg martingál.

Ehhez annyinak kell igaznak lennie, hogy a sztochasztikus integrálnak nem szabad hogy mértékszivárgása legyen, ami abszolút megtörténhet, mivel a Heston-modell a variancia sztochasztikus változása miatt egy kevert normális eloszlású súlyfüggvényt ad. Vagyis amennyiben teljesül, hogy nincs mértékszivárgás, folyamat sztochasztikus integrálja martingál.

1.3.1 A Sztochasztikus integrálok második momentuma- inak létezésének feltételei

A kérdés tehát az, hogy igaz-e, hogy

$$E \left(\int_t^T v_s S_s^2 \left(\frac{\partial F}{\partial S} \right)^2 ds \right) < \infty$$

Tegyük fel, hogy teljesül európai call opciókra heston modellben, a peremfeltétel miatt hogy $0 \leq \frac{\partial F}{\partial S} \leq 1$. Ekkor, mivel az Ázsiai opcióknak az árrugalmassága az átlag figyelembevétel miatt nem akkora mint az európai opcióknak, fennáll hogy $v S^2 \left(\frac{\partial F}{\partial S} \right)^2 \leq v S^2$. Továbbá, még azt is észre lehet venni, hogy

$$(dS_s)^2 = d[S, S] = ((\mu S_s ds + \sqrt{v_s} S_s dW_{1,s})(\mu S_s ds + \sqrt{v_s} S_s dW_{1,s})) = v S^2 ds$$

amiben észrevehetjük, ha szemfülesek vagyunk, hogy a $d[S, S]$ az Ito lemma kvadratikusan variációs tagja amennyiben a $d(S_s^2)$ -t nézzük:

$$d(S_s^2) = 2S \bullet S + 2 \frac{1}{2} d[S, S] = v S^2 ds + 2S(r S ds + \sqrt{v} S dW) = (v + 2r) S^2 ds + \sqrt{v} S dW$$

Azaz:

$$\begin{aligned} E(S_T^2 - S_t^2) &= E \left(\int_t^T (v + 2r) S^2 ds \right) + E \left(\int_t^T \sqrt{v} S dW \right) = \\ &= E(S_T^2) - S_t^2 = E \left(\int_t^T v S^2 ds \right) + E \left(2r \int_t^T S^2 ds \right) + E \left(\int_t^T \sqrt{v} S dW \right) \end{aligned}$$

Fubini, és $E \left(2r \int_t^T S^2 ds \right)$ Átvitele a baloldalra:

$$E \left(\int_t^T v S^2 ds \right) = E(S_T^2) - S_t^2 - E \left(2r \int_t^T S^2 ds \right)$$

Most azt kell belátnunk, hogy

$$E \left(\int_t^T S^2 ds \right) < \infty$$

Alkalmazzuk az Andersen–Piterbarg (2007) tételt 34-35. oldal <https://link.springer.com/article/10.1006-0011-7> a standard Heston-modell jelöléseire:

- A vizsgált momentum: $\omega = 2$
- Az árfolyam diffúziós szorzója: $\lambda = 1$
- A variancia volatilitása: $\varepsilon = \sigma_v$

Először határozzuk meg a tétel konstansát:

$$k = \frac{\lambda^2}{2} \omega (\omega - 1) = \frac{1^2}{2} 2(2 - 1) = 1$$

A tétel szerinti paraméterek:

$$b = \frac{2k}{\varepsilon^2} = \frac{2}{\sigma_v^2}$$

$$a = \frac{2(\rho\varepsilon\lambda\omega - \kappa)}{\varepsilon^2} = \frac{2(\rho\sigma_v(1)(2) - \kappa)}{\sigma_v^2} = \frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2}$$

A diszkrimináns ($D = a^2 - 4b$) felírása:

$$D = \left(\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2} \right)^2 - \frac{8}{\sigma_v^2} = \frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4}$$

A tétel (1)-es pontja alapján a (T^*) (ami gyakorlatilag az időt mutatja, amíg a bizonyos ω momentum létezik) akkor lesz végtelen, ha $a < 0$ és $D \geq 0$ egyszerre teljesül. Az $a < 0$ feltétel jelentése:

$$\frac{4\rho\sigma_v - 2\kappa}{\sigma_v^2} < 0 \quad \implies \quad 2\rho\sigma_v < \kappa$$

Mivel a mean-reversion sebesség $\kappa > 0$, és mivel jellemzően $\rho \leq 0$, ez az egyenlőtlenség a gyakorlatban szinte mindig triviálisan teljesül. A $D \geq 0$ feltétel jelentése:

$$\frac{4(\kappa - 2\rho\sigma_v)^2 - 8\sigma_v^2}{\sigma_v^4} \geq 0 \quad \implies \quad (\kappa - 2\rho\sigma_v)^2 \geq 2\sigma_v^2$$

Gyökvonás után (tudva, hogy a bal oldal az $a < 0$ miatt pozitív):

$$\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$$

Amennyiben a piacról kalibrált paraméterek kielégítik a $\kappa - 2\rho\sigma_v \geq \sqrt{2}\sigma_v$ egyenlőtlenséget, a tétel (1)-es esete lép életbe, azaz a momentum-robbanás kritikus időpontja $T^* = \infty$. Mivel bármely árazandó opció lejáratát (T) egy véges szám, a $t \leq T < T^*$ feltétel ($T < \infty$) automatikusan teljesül. Ez szigorúan bizonyítja, hogy az $E[S_s^2]$ a teljes árazási horizonton véges marad. Innen tudjuk, hogy mivel véges, véges időhorizonton az integrálja is az, fennáll rá a Fubini-tétel,

$$\int_t^T E[S_s^2] ds = E\left(\int_t^T S_s^2 ds\right) < \infty$$

vagyis az integrál véges. Azaz:

$$E\left(\int_t^T v_s S_s^2 ds\right) < \infty$$

Nézzük a másik tagot!

$$E\left(\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s}\right)^2 ds\right) < \infty$$

Nézzük meg a vizsgálandó kifejezést:

$$E\left[\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s}\right)^2 ds\right]$$

. Itt sajnos az a nehézség, hogy nem tudunk szinte semmit erről az integrálról. Ennek szigorú analitikus bizonyítása ázsiai opciók esetén egy eléggé komplex feladat, sőt, egyáltalán nem bizonyos, hogy igaz minden esetben, milyen paraméterek mellett az. Tehát vagy azt kell feltételeznünk, hogy az integrál várható értéke véges, vagy amennyiben be tudnánk bizonyítani, hogy $\left(\frac{\partial F}{\partial v_s}\right)^2$ érték felülről korlátos, akkor martingál lesz ez a sztochasztikus tag is. Ekkor ugye létezik egy $M > 0$ konstans, amire $\left(\frac{\partial F}{\partial v_s}\right)^2 \leq M^2$, vagyis a fenti várható értékre igaz, hogy:

$$E\left[\int_t^T \sigma_v^2 v_s \left(\frac{\partial F}{\partial v_s}\right)^2 ds\right] \leq E\left[\int_t^T \sigma_v^2 v_s M^2 ds\right] \stackrel{Fubini}{=} \sigma_v^2 M^2 \int_t^T E[v_s] ds$$

Innen már könnyű, hiszen tudjuk, hogy a v_s egy CIR folyamat. A CIR folyamat várható értéke bármely s időpontban egy egzakt, ismert, véges kifejezés:

$$E[v_s] = \theta + (v_t - \theta)e^{-\kappa(s-t)}$$

Mivel az $E[v_s]$ függvény folytonos és véges, a véges $[t, T]$ intervallumon vett integrálja is garantáltan véges lesz. Tehát ha a derivált korlátos, a teljes sztochasztikus integrál várható értéke automatikusan véges marad, így az Ito-formula dW_2 -höz tartozó tagja is valódi martingál lesz. Azaz az Ito-formula szerinti drift tag kinullázásával megkapjuk a keresett árazó parciális differenciálegyenletet. Ezzel kizártuk a mértékszivárgást, azaz igaz, hogy :

$$E^Q[F(X_T) - F(X_t)] = E^Q \left[\int_t^T rF(X_s) ds \right]$$

$$E^Q(dF) =$$

$$\begin{aligned} E^Q \left[\left[\frac{\partial F}{\partial t} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds \right] + \\ + E^Q \left[\left[\sqrt{v} S \frac{\partial F}{\partial S} dW_1 + \sigma_v \sqrt{v} \frac{\partial F}{\partial v} dW_2 \right] \right] \\ \xrightarrow{\text{martingál tul. miatt}} \\ = E^Q \left[\left[\frac{\partial F}{\partial t} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} \right] ds \right] \\ \xrightarrow{\text{arbitrázsmentesség}} 0 = E^Q \left[\int_t^T dF_s - rF(X_s) ds \right] = \end{aligned}$$

$$\frac{\partial F}{\partial t} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} - rF = 0$$

ami a PINN-emben a PDE lesz. A parciális differenciál egyenlet rendszer premeftétele pedig:

$$\begin{cases} \frac{\partial F}{\partial t} + \frac{1}{2} v S^2 \frac{\partial^2 F}{\partial S^2} + \rho \sigma_v v S \frac{\partial^2 F}{\partial S \partial v} + \frac{1}{2} \sigma_v^2 v \frac{\partial^2 F}{\partial v^2} + rS \frac{\partial F}{\partial S} + \kappa(\theta - v) \frac{\partial F}{\partial v} + S \frac{\partial F}{\partial A} - rF = 0 \\ F(T, S, v, A) = \max \left(\frac{A}{T} - K, 0 \right) \end{cases} \quad \text{ha } t = T$$

lesz, ahol a a lejáratkori kifizetés a peremfeltétel.

1.4 Tételek alkalmazása a PINN-modellben

A jelen dolgozat célja egy olyan kifejlesztett PINN bemutatása, ami betanítás után, X ismeretével konstans időben árazza, valamint számolja ki a fedezéshez szükséges görögöket.

Ezt úgy teszi meg, hogy gyakorlatilag egy veszteségfüggvényt minimalizál úgy, hogy minden körben(epochban) becsül egy megoldást, egy függvény tetszőlegesen választott pontjaira, és a becsült megoldások behelyettesítésével és a valódi megoldások értékei közötti átlagos négyzetes hibát veszi veszteségnek.

1.4.1 Peremfeltételek a PINN modellben.

A parciális differenciálegyenletek megoldása során a peremfeltételek határozzák meg a rendszer viselkedését a vizsgált tartomány határain. A PINN architektúrákban ezeket a feltételeket nem merev korlátokként, hanem a veszteségfüggvény büntetőtagjaiként (MSE, vagyis átlagos négyzetes eltérés) érvényesítjük.

$S_\tau = 0$ peremfeltétel

Ha a részvény árfolyama nullára esik egy τ időpontban ($S = 0$), akkor, $S_{t>\tau}$ időpontban is 0 lesz, hiszen a folyamat driftje, és volatilitása is arányos S -sel, így onnan már nem tud elmozdulni. Így az opció kifizetése :

$$(\frac{1}{T}A_T - K)^+ = (\frac{1}{T}A_\tau - K)^+$$

lesz.

Mivel ezek a τ időpontok különbözőek lehetnek, és itt

$$\hat{F}(t, S_t, A_t, v_t) = \hat{F}(\tau, 0, A_\tau, v_\tau),$$

Bár a kifizetés pontos összege már a τ pillanatban ismertté válik, maga a pénzáramlás (a szerződés teljesítése) csak a T lejáratkor történik meg.

Emiatt a τ időpontban az opció piaci értékét a jövőbeli biztos kifizetés jelenértéke határozza meg. A hátralévő $T - \tau$ várakozási időre alkalmaznunk kell az $e^{-r(T-\tau)}$ diszkontfaktort. Megvalósítás tekintetében, nem a max függvényt raktam

$S_{max} \rightarrow \infty$ (Neumann-peremfeltétel)

A Carl Neumann (1832–1925) által bevezetett feltétel nem a függvény értékét, hanem valamely deriváltját határozza meg a peremen. Fizikai analógiája a peremen megadott hőáramlás (például képzeljünk el egy tökéletes szigetelést, ahol ugye a hőáramlás deriváltja nulla).

A Heston-modellben a felső peremen $S \rightarrow \infty$, (gyakorlatban $S = S_{max}$) Neumann-feltételt használunk. Amikor a részvény ára extrém magasra nő, az opció majdnem biztosan le lesz hívva, így átlag megegyezik az Árfolyammal. Ekkor ez egy lineáris függvény, mivel az opció lehívásra kerül, melynek második deriváltja (vagyis az opció Gammája) nulla. Ezt a másodrendű Neumann-feltételt így formalizáljuk:

$$\frac{\partial^2 F}{\partial S_{max}^2} = 0$$

A PINN architektúrában az automatikus differenciálás segítségével az (háló kimenetének) S szerinti második deriváltját közvetlenül beépítjük a veszteségfüggvénybe.

$$Loss_{S_{max}} = \frac{1}{N_{perem}} \sum_{i=1}^{N_{perem}} \left(\frac{\partial^2 \hat{F}}{\partial S^2} \Big|_{S_i=S_{max}} - 0 \right)^2$$

1.4.2 Veszteségfüggvény

Valójában ezek a peremfeltételek arra kellettek, hogy jó megoldásra tanuljon rá a PINN-em, mivel ugye a Heston-modell egy parabolikus PDE, azaz elvben végtelen megoldása van. Viszont a peremfeltételek garantálják, hogy egy megoldása legyen a parabolikus PDE-nek.

A modell teljes veszteségfüggvénye a peremfeltételek, a belső pontokon kiértékelt PDE reziduális, valamint a lejáratkori ($t = T$) peremfeltétel hibáinak összegeként áll elő. Ekkor a veszteségfüggvény:

$$\mathcal{L}_{loss} = \mathcal{L}_{pde} + \mathcal{L}_{ic} + \mathcal{L}_{Smax} + \mathcal{L}_{Smin}$$

ahol F a valódi értéket, $\hat{F}$ jelölés a becsült értéket jelenti, és

$$\mathcal{L}_{pde} = MSE\left(\frac{\partial \hat{F}}{\partial t} + \frac{1}{2}vS^2\frac{\partial^2 \hat{F}}{\partial S^2} + \rho\sigma_v vS\frac{\partial^2 \hat{F}}{\partial S\partial v} + \frac{1}{2}\sigma_v^2 v\frac{\partial^2 \hat{F}}{\partial v^2} + rS\frac{\partial \hat{F}}{\partial S} + \kappa(\theta - v)\frac{\partial \hat{F}}{\partial v} + S\frac{\partial \hat{F}}{\partial A} - r\hat{F}\right)$$

$$\mathcal{L}_{ic} = MSE(\hat{F}_{ic} - Softplus(\frac{1}{T}A_T - K))$$

$$\mathcal{L}_{Smin} = MSE(\widehat{F_{Smin}} - Softplus(\frac{1}{T}A_{\tau_0} - K))$$

$$\mathcal{L}_{Smax} = MSE(\frac{\partial^2 \widehat{F}}{\partial S_{max}^2})$$

Ahol a Softplus függvény a hivatalos pytorch dokumentáció szerint: <https://docs.pytorch.org/docs/stable/generated/torch.nn.functional.softplus.html> egy jó approximációja a ReLu, függvénynek, ami a $\text{Max}(x, 0)$ függvény. Azért kell, mert a max függvény nem deriválható a 0 helyen, viszont deriválható függvények kellenek, hiszen a gradiens ereszkedés miatt elengedhetetlen ez a feltétel. A Softplus képlete:

$$Softplus(x) = \frac{1}{\beta} \ln(1 + e^{(\beta x)})$$

Ezenkívül, beleraktam még egy Monte Carlo szimulációt, egyrészt azért, hogy T időponton kívül $t = 0$ időpontban is legyenek adataink, azért hogy a háló-
nak legyenek viszonyítási pontjai az áfolyamintervallumon kívül az időinter-
vallum mindkét végén is. Továbbá így jobban rá tud tanulni a valós árra a
kezdő időpontban is.

A 0. időpontban egyenletesen generáltam 2000 árat (S_0) 0.01, és 5 között, és generáltam 2000 varianciát (v_0) 0.0001, és 1 között. Mindegyik kezdőár és variancia párosra lefuttattam 20000, 100 egyenlő lépésre diszkretizált utat, a Heston modell diszkretizált árfolyam dinamikája szerint. Így kiszámoltam 2000 kezdőár és variancia párosra az opció árát a 0. időpontban.

Ezután beleraktam valamilyen súlyokat (λ) az új veszteségfüggvénybe:

$$\mathcal{L}_{loss} = \lambda_1 \mathcal{L}_{pde} + \lambda_2 \mathcal{L}_{ic} + \lambda_3 \mathcal{L}_{Smax} + \lambda_4 \mathcal{L}_{Smin} + \lambda_5 \mathcal{L}_{MC}$$

Itt az

$$\mathcal{L}_{MC} = MSE(F_{MC} - \widehat{F_{MC}})$$

A lambda értékeket az alábbiak szerint határoztam meg:

$$\lambda_1 = 10, \lambda_2 = 7, \lambda_3 = 1, \lambda_4 = 1, \lambda_5 = 1$$

2.1 A hálózati architektúra

A tanítást egy NVIDIA GeForce RTX 3090-os processzoron végeztem el, amely 24GB VRAM-al rendelkezik. Mivel 4 dimenziós a probléma, ezért sok pontot kellett megvizsgálnom. Dimenzióként körülbelül 150 pontból szerettem volna betanítani a függvényt, így $5 \cdot 10^{2 \cdot 4}$ -ra löttem be a vizsgálandó pontok számát.

2.1 Hálózat felépítése

A hálóm 7 darab lineáris függvényt és 6 darab aktivációs függvényt tartalmaz, egymásba ágyazva, az utolsó lineáris függvény után értetlemszerűen már nincs aktivációs függvény. A lineáris függvények 4×256 , 256×256 , 256×256 , 256×256 , 256×256 , 256×128 , 128×1 méretűek.

Aktivációs függvénynek LAAF-tanh-t választottam (Locally Adaptive Activation Function) amely úgy néz ki, hogy:

$$\frac{e^{nx} - e^{-nx}}{e^{nx} + e^{-nx}}$$

ahol n egy tanulható paraméter, ami úgy tanul, hogy kiszámolja az $\frac{\partial \mathcal{L}_{loss}}{\partial n}$ -t és eszerint a gradiens szerint növeli, vagy csökkenti az n paramétert úgy, hogy a hibát minimalizálja.

2.2 Adatok skálázása

A bemeneti változók normalizálása nem csupán a PINN architektúrák, hanem általánosságban minden neurális hálózat betanításának egyik legfontosabb alapfeltétele. A Heston-Asian modell paraméterei nagyságrendileg jelentősen eltérnek egymástól: a variancia jellemzően nagyon kicsi ($v \in [0.0001, 1]$), míg a részvényárfolyam és az átlag nagyobb tartományt fed le ($S, A \in [0, 5]$).

Ha ezeket az adatokat nyers formában táplálnánk be a hálózatba, az két súlyos, a gépi tanulásban jól ismert problémához vezetne:

- **A veszteségfüggvény torzulása:** A bemenetek nagyságrendi különbségei miatt a hibafelületen a völgyek ellipszoid alakká torzulnának. Az optimalizáló algoritmus az egyik paramétert aránytalanul jobban és gyorsabban optimalizálná, míg a másik mentén alig haladna, ami instabil és rendkívül lassú konvergenciát eredményez.
- **Az aktivációs függvények szaturációja :** Az összetett függvényben tanh aktivációs függvényeket használunk, amelyek a nulla körüli tartományban a legaktívabbak (itt a legmeredekebb a deriváltjuk). A skálázatlan, nagy bemeneti értékek a neuronok kimenetét azonnal a tanh függvény lapos, végeire tolnák. Ez azért történik meg, mert

$$\tanh'(x) = 1 - \tanh^2(x)$$

, ami $x = 0$ -tól kezdve bármelyik irányba nagyon gyorsan konvergál 0, hoz. Ez azt eredményezi, hogy sokkal lassabban tanul a háló, már nagyságrendileg közel lévő értékek esetén is.

A PINN-ek esetében ez az általános gépi tanulási szabály hatványozottan fontos. Mivel a PDE reziduális kiszámításához másodrendű deriváltakra is szükség van, az első deriváltak 0-hoz való konvergálásuk miatt megszünteti a másodrendű deriváltakat.

Ennek elkerülése érdekében egy skálázó objektumot alkalmaztam, amely minden bemeneti dimenziót szigorúan a $[-1, 1]$ zárt intervallumra transzformál az alábbi normalizáció segítségével. Egy tetszőleges x bemenetre a transzformáció képlete:

$$x_{scaled} = 2 \frac{x - x_{min}}{x_{max} - x_{min}} - 1$$

A neurális háló kizárólag ezeken a normalizált értékeken operál. Így az optimalizációs tér topológiája gömbszerűbbé, kiegyensúlyozottabbá válik, az aktivációs függvények pedig az aktív tartományukban maradnak. Megjegyzendő, hogy a PDE kiértékelésekor az automatikus differenciálás láncszabálya miatt a deriváltakat a fentebb bemutatott skálázás inverzével megfelelően korrigálni kell, hogy a PDE érvényes maradjon.

2.3 Mintavételezés: Latin Hypercube Sampling (LHS)

A fizikai tér letapogatása során egy 4 dimenziós tartományt kell lefednünk. A klasszikus, egyenletes rácsponos felosztás miatt exponenciálisan növekvő adathalmazt eredményezne, míg a tisztán egyenletes mintavétel során a pontok hajlamosak csomósodni, nagy, üresen tátongó lyukakat hagyva a 4 dimenziós térben.

Ezen probléma áthidalására a Latin Hypercube Sampling algoritmust alkalmaztam. Az LHS úgy működik, hogy a pontokat úgy helyezi el a térben, hogy a tér lehető legnagyobb részét kitöltse, az

A modellemben a mintavételező algoritmus (a kódomban: Sampler) ezt kiegészíti egy a pontokat a strike price köré sűrítő transzformációval is az S és A tengelyek mentén, hiszen a deriváltak (például az opció Gammája) itt a legnagyobbak és legnehezebben tanulhatók.

2.4 Kétfázisú optimalizáció és dinamikus rács

1. Fázis: Dinamikus Adam optimalizáció

Az első szakaszban az Adam optimalizálót használjuk, amely jól kezeli a zajos, komplex felületeket. A 4 dimenziós (t, S, v, A) fázistér kezdeti felfedezése során egy komoly hardveres korlátba ütköztem: a rendelkezésre álló grafikus kártya memóriája (24 GB VRAM) nem teszi lehetővé, hogy a tér lefedéséhez

szükséges több tízmillió pontot egyidejűleg a memóriában tartson, és azokon másodrendű deriváltakat számoljon.

Ezt a problémát egy dinamikus mintavételezési stratégiával hidaltam át, amely a hardveres problémát megoldja. Annak érdekében, hogy a memória ne teljen meg, de a hálózat a tér lehető legnagyobb részéből vegyen mintát, minden egyes epoch elején 25 000 teljesen új ponton generáltattam a térben.

Ez a folyamatos újra-mintavételezés garantálja, hogy bár a VRAM terhelése alacsony marad, a több ezer epoch alatt a hálózat folyamatosan friss, korábban nem látott pontokkal találkozik a folytonos térből.

A betanításba beépítettem egy bemelegítő fázist is. Az első 1000 epoch során a parciális differenciálegyenlet büntetőtagjának súlyát (λ_{pde}) nullára állítottam. A PDE kikapcsolásával a hálózat először közelítőleg megtanulja a fontos peremfeltételeket.

2. Fázis: L-BFGS másodrendű finomhangolás

Sajnos az adam optimizer, a globális minimum közvetlen közelében hajlamos oszcillálni. A hajszálpontos árazás, és a görögök számítása érdekében a tanítást az L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno) algoritmussal zártam.

Az L-BFGS a Hesse-mátrix inverzét közelíti, így figyelembe veszi a hibafelület görbületét is, ami rendkívül gyors és elég pontos konvergenciát biztosít a minimum pont felé. Mivel ez a módszer line search-t alkalmaz, így egy adott irányban többször is kiértékeli a függvényt, ezért a mintavételezési pontoknak szigorúan statikusnak kell lenniük. Ezért ebben a fázisban egy hatalmas, fix pontokból álló rácsot (50 000 belső pont és perempontok) szögeztem le, és ezen végeztem el az utolsó iterációkat, garantálva a PDE reziduálisok maximális kisimítását. Kicsit pontosabban, ez tulajdonképpen a Newton-Raphson módszeren alapul. Ugye az a cél, hogy megtaláljuk a függvény minimumát, vagyis amikor $\nabla f(x) = 0$. A Newton-Raphson szerint egy dimenzióban ekkor:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Vagyis több dimenzióban a Hesse-mátrix inverzével kell szorozni a gradienst minden lépésben. Az L-BFGS-ben a Hesse-mátrixot approximálják minden lépésben, ahogy egy dimenzióban is tennénk a deriváltak különbségével: $H \approx \frac{f'(x_k) - f'(x_{k-1})}{x_k - x_{k-1}}$, és a számításához ennek az inverzére (egydimenziós esetben a reciprokára) van szükség. Azaz a többdimenziós képlet:

$$x_{k+1} = x_k - \alpha_k B_k^{-1} \nabla f(x_k)$$

ahol a B_k a Hesse-mátrix approximációja, az α_k pedig a learning rate.

Így gyakorlatilag az első fázis megkereste elég jól a globális minimum környékét, a második fázis pedig a globális minimumot. <https://arxiv.org/html/2501.16371v1>

Azaz az algoritmusom az alábbi kettő egymást követve:

Algorithm 1 Dinamikus Heston-Asian PINN Tanító Algoritmus (1. Fázis: Adam)

Require: $\mathcal{T}_{max}$ (lejárat), N_{Adam} (Adam epochok száma), batch méretek, Heston paraméterek, η (tanulási ráta)

Ensure: Részben betanított neurális háló $\hat{F}_\theta(t, S, v, A)$

1: $\theta \leftarrow$ Inicializált hálózati paraméterek

1. FÁZIS: Adam Optimalizáció

2: **for** $e = 1$ **to** N_{Adam} **do**

3: Batchnyi belső pont generálása LHS-sel, majd a polinomiális torzítás:
 $\mathcal{P}_{in} \sim \mathcal{U}(\Omega)$

4: Batchnyi peremfeltétel, és kezdeti feltétel generálás: $\mathcal{P}_{bc}, \mathcal{P}_{ic} \sim \mathcal{U}(\partial\Omega)$

5: **if** $e \leq 1000$ **then**

6: $\lambda_{PDE} \leftarrow 0$

7: **else**

8: $\lambda_{PDE} \leftarrow 10$

9: **end if**

10: **Forward:**

11: Veszi a Batch size-nyi mintapontot, majd belerakja őket a becslőfüggvénybe.

12: **Veszteségfüggvény összeállítása:**

13: **if** $1 < S_{in} \leq 2.1$ és $A < 1.6$ **then**

14: $\lambda_{PDE} \leftarrow 20\lambda_{PDE}$

15: $\lambda_{MC} \leftarrow 20\lambda_{MC}$

16: **end if**

17: $\mathcal{L}(\theta) = \lambda_{PDE}\mathcal{L}_{PDE}(\theta) + \lambda_{ic}\mathcal{L}_{ic}(\theta) + \lambda_{bc}\mathcal{L}_{bc}(\theta) + \lambda_{mc}\mathcal{L}_{MC}(\theta)$

18: **Backpropagation:**

19: Célfüggvény gradienseinek számítása automatikus differenciálással:
 $g \leftarrow \nabla_\theta \mathcal{L}(\theta)$

20: **Paraméterek frissítése:**

21: $\theta \leftarrow \theta - \eta \cdot \text{Adam}(g)$

22: **end for**

Algorithm 2 Dinamikus Heston-Asian PINN Tanító Algoritmus (2. Fázis: L-BFGS)

Require: Részben betanított háló (az Adam fázisból), N_{LBFGS} (L-BFGS iterációk száma)


Ensure: Véglegesen betanított neurális háló $\hat{F}_\theta(t, S, v, A)$

2. FÁZIS: L-BFGS

- 1: Statikus pontok kijelölése fix perem- és kezdeti pontokkal: $\mathcal{P}_{static_lbfgs}$
 - 2: **Definiáljuk a Closure(θ) függvényt az L-BFGS-hez**
 - 3: **Forward pass** a $\mathcal{P}_{static_lbfgs}$ pontokon
 - 4: $\mathcal{L}(\theta) \leftarrow$ Teljes veszteségfüggvény kiszámítása
 - 5: **Backpropagation:** $g \leftarrow \nabla_\theta \mathcal{L}(\theta)$
 - 6: **return** $\mathcal{L}(\theta)$
 - 7: **while** Konvergencia kritérium nem teljesül és iterációk $\leq N_{L-BFGS}$ **do**
 - 8: **Paraméterek frissítése (Newton-Raphson logika, Hesse-mátrix approximációval):**
 - 9: **if** $1 < S_{in,MC} \leq 2.1$ és $A_{in} < 1.6$ **then**
 - 10: $\lambda_{PDE} \leftarrow 80 \cdot \lambda_{PDE}$
 - 11: $\lambda_{MC} \leftarrow 20 \cdot \lambda_{MC}$
 - 12: **end if**
 - 13: $\theta \leftarrow \text{L-BFGS_Step}(\theta, \text{Closure})$ $\triangleright$ Többszöri kiértékelés a Closure hívásával a PyTorch beépített L-BFGS optimalizálójában
 - 14: **end while**
-

A legrosszabb pontok elhelyezkedését vizsgáltam minden lehetséges dimenziókombináció mellett. 1 millió pont mellett, a legrosszabb 10000 pont elhelyezkedését az adott 2500 pontos téren dimenzióként. Látható, hogy a skötési ár környékét is nagyon jól megtanulta a háló

A Legrossabb 1% PDE Hibájú Pontok Eloszlása (Hőterképek)



1. ábra. Enter Caption


1. táblázat. Keresési feltételek: $\tau > 0.01$, $v < 0.6$, $A > 0.3$, $S < 4.0$

#	S (Árfolyam)	A (Átlag)	τ	v (Variancia)	PDE Hiba (MSE)
1	3.2875	0.3264	0.44	0.0021	3.895045e-04
2	3.4127	0.4381	0.43	0.0038	2.549874e-04
3	3.2619	0.3446	0.45	0.0139	2.535569e-04
4	3.9900	1.0611	0.13	0.0677	2.463991e-04
5	3.5470	0.4341	0.40	0.0121	2.418481e-04
6	3.7246	0.4909	0.34	0.0073	2.326770e-04
7	2.5110	0.3461	0.58	0.0022	2.239831e-04
8	3.7350	0.5415	0.33	0.0108	2.223665e-04
9	3.8661	0.4002	0.31	0.0022	2.202430e-04
10	3.9973	1.4600	0.02	0.0882	2.189857e-04

Futtattam továbbá egy monte carlo szimulációt, 10000 opció árát vizsgáltam, 1000 ebből a $t = 0$. időpontban, 9000 pedig egyenletes eloszlással vett időpontokban. Az 1000 $t = 0$. egyenletes eloszlással sorsolt (v , és S szerint) időpontból, futtattam egyenként 9 szimulált utat, majd minden úthoz egyenletes eloszlással vettem egy időpontot. Ebben az időpontban megvizsgáltam, hogy mennyi az átlag, ár, variancia. Így létrehoztam 9000 új pontot, amelyek realisztikusak. 1 000 000 szimulációt futtattam 500 lépéssel az adott 10000 pontból, a heston modell dinamikája szerint, majd azt vizsgáltam, hogy a PINN eredmény mennyire tér el a Monte Carlo eredményétől.

2. táblázat. A PINN modell validációs statisztikái ($N = 10\,000$ tesztpont alapján)

Hiba metrika megnevezése	Számított érték
Mean Absolute Error (MAE)	1.956000e-03
Max Absolute Error	7.500600e-02
Mean Relative Error (MRE)	2.25%
Median Relative Error	0.17%




2. ábra. Enter Caption


3. táblázat. Hibastatisztika a moneyness kategóriák szerint

Kategória	Pontok	Átl. MC Ár	Absz. Hiba	Med. Rel. (%)	Rel. Hiba (%)
Deep OTM	328	0.0321	1.5000e-03	8.08%	3.93%
OTM	595	0.0769	2.4000e-03	9.97%	3.33%
ATM	514	0.1521	3.4000e-03	11.41%	1.48%
ITM	829	0.2852	2.1000e-03	2.78%	0.53%
Deep ITM	4217	1.0352	1.6000e-03	0.47%	0.14%

PINN Modell Hibáinak Eloszlása a Valós (MC) Opció Ár Függvényében



3. ábra. Enter Caption



4. ábra. Enter Caption

Az opciós árak mellett validáció gyanánt a Delta pontosságát is kiértékeltem, melynek MC becsléséhez azonos véletlen számok szerinti centrális differenciamódszert alkalmaztam.

$$\text{Delta} \approx \frac{U(S + \varepsilon; Z) - U(S - \varepsilon; Z)}{2\varepsilon}$$


Itt a jelölések a következőket jelentik:

U : Az opció becsült jelenértéke (ára) a Monte Carlo szimuláció végén.

S : Az aktuális részvényárfolyam.


ε : A kis mértékű eltolás, ami a kódban a $h = 0.01$ paraméter.

Z : Sztochasztikus mag (ugyanaz $\pm\varepsilon$ szimulációknál)




5. ábra. Enter Caption


Relatív hiba eloszlása az állapotór paramétereit szerint




6. ábra. Enter Caption




7. ábra. Enter Caption




8. ábra. Enter Caption




9. ábra. Enter Caption



10. ábra. Enter Caption



11. ábra. Enter Caption



12. ábra. Enter Caption